

Análisis del perfil de clientes y su comportamiento de compra — Informe técnico

Documentación técnica del proceso de análisis exploratorio, tratamiento de calidad de datos e imputación de outliers.

Dataset original
2,205 registros — 39 variables

Dataset final
2,205 registros — 23 variables

Método de imputación
Capping

Gabriel Parrales Gutiérrez
Data Analyst | BI Consultant

01 Análisis exploratorio de datos (EDA)

El dataset original cuenta con 2,205 registros y 39 variables. Durante el análisis inicial se identificaron los siguientes problemas de calidad:

- Inexistencia de la variable ID.
- Income, MntWines, MntFruits, MntMeatProducts, MntFishProducts, MntSweetProducts, MntGoldProds y MntTotal almacenaban montos monetarios como texto, con el carácter "\$", impidiendo su análisis sin transformación previa.
- Estado civil y educación codificados en múltiples variables binarias (marital_*, education_*).
- Presencia de outliers en variables de comportamiento de compra y en variables de monto por categoría.




Distribución demográfica y de comportamiento

- Las edades se concentran mayoritariamente en el rango 40–49 años (691 clientes), seguido de 50–59 (528) y 60–69 (473).
- La mayoría de los clientes no posee niños (1,276 con 0 niños) ni adolescentes (1,139 con 0 adolescentes) en el hogar.
- Casi la totalidad de los clientes tiene una permanencia de 6 años (1,147) o 7 años (982).
- Casi el 50% de los clientes visita la página web de 6 a 8 veces al mes.

Outliers en variables de comportamiento

VARIABLE	% OUTLIERS	CANT.	LÍM. SUP.
NumWebPurchases	0.14%	3	11
NumCatalogPurchases	0.91%	20	10
NumDealsPurchases	3.72%	82	6
NumWebVisitsMonth	0.36%	8	13

Las compras en línea y en tienda tienen buena acogida; ~25% de los clientes no compra por catálogo. Con ofertas, los clientes llegan a realizar hasta 15 compras.



02 Preprocesamiento y estadística descriptiva

Se convirtieron a tipo numérico las variables Income, MntWines, MntFruits, MntMeatProducts, MntFishProducts, MntSweetProducts, MntGoldProds y MntTotal (originalmente texto con el carácter "\$").

ESTADÍSTICO	INCOME	MNTWINES	MNTFRUITS	MNTMEAT	MNTFISH	MNTSWEET	MNTGOLD	MNTTOTAL
Media	51,622.09	306.16	26.40	165.31	37.76	27.13	44.06	562.76
Desv. Est.	20,713.06	337.49	39.78	217.78	54.82	41.13	51.74	575.94
Mín.	1,730	0	0	0	0	0	0	4
25%	35,196	24	2	16	3	1	9	56
50%	51,287	178	8	68	12	8	25	343
75%	68,281	507	33	232	50	34	56	964
Máx.	113,734	1,493	199	1,725	259	262	321	2,491

Outliers en variables de monto (post-conversión)

VARIABLE	Q1	MEDIANA	Q3	RIC	% OUTLIERS	CANT.	LÍM. SUP.
Vinos	24	178	507	4	1.54%	34	1230.53
Frutas	2	8	33	31	11.11%	245	79.14
Pescado	3	12	50	47	10.07%	222	120.06
Dulces	1	8	34	33	10.79%	238	83.19
Productos Premium	9	25	56	47	9.25%	204	126.13
Cárnicos	16	68	232	216	7.71%	170	555.21

La suma de los montos por categoría difiere del valor de MntTotal, por lo que fue necesario reconstruir una nueva columna "Monto Total" con el cálculo correcto (suma de las 6 categorías).

03 Imputación de datos

Se ejecutaron dos métodos de imputación de outliers: **reemplazo por mediana** y **capping** (sustitución del outlier por el límite superior). A continuación, la comparación de resultados:

Variables de conteo (compras y visitas)


VARIABLE	PROM. MEDIANA	MED. MEDIANA	DE MEDIANA	PROM. CAPPING	MED. CAPPING	DE CAPPING
Compras web	4.07	4	2.63	4.08	4	2.64
Compras catálogo	2.56	2	2.63	2.63	2	2.73
Compras con descuento	2.07	2	1.34	2.22	2	1.53
Visitas web mensuales	5.29	6	2.29	5.32	6	2.33

Variables de monto por categoría

VARIABLE	PROM. MEDIANA	MED. MEDIANA	DE MEDIANA	PROM. CAPPING	MED. CAPPING	DE CAPPING
Vinos	288.17	178	311.55	304.39	178	332.11
Frutas	13.68	8	17.62	21.56	8	26.82
Pescado	21.36	12	27.81	32.23	12	40.33
Dulces	14.15	8	18.54	22.25	8	28.04
Productos Premium	30.22	25	28.67	39.56	25	39.76
Cárnicos	113.31	68	135.14	150.86	68	178.16

DECISIÓN METODOLÓGICA


Para las variables de conteo (compras, visitas) ambos métodos producen resultados casi idénticos. Para las variables de monto, el reemplazo por mediana deja outliers residuales, mientras que el **capping los elimina por completo** (a cambio de aumentar la desviación estándar). Se optó por **capping** como método de imputación para todo el dataset, priorizando la eliminación completa de datos atípicos sobre la minimización de la variabilidad.



Web	Catálogo	Ofertas
Primer cuartil: 2	Primer cuartil: 0	Primer cuartil: 1
Mediana: 4	Mediana: 2	Mediana: 2
Tercer cuartil: 6	Tercer cuartil: 4	Tercer cuartil: 3
RIC: 4	RIC: 4	RIC: 2
Outliers: 0.14% (3)	Outliers: 0.91% (20)	Outliers: 3.72% (82)
Límite superior: 11	Límite superior: 10	Límite superior: 6


Monto gastado en vino.

Reemplazo de outliers con la mediana:



Promedio: 288.17
Mediana: 178
Desv. Estándar: 311.55

Método de Capping



Promedio: 304.39
Mediana: 178
Desv. Estándar: 332.11

Monto gastado en frutas.

Reemplazo de outliers con la mediana:



Promedio: 13.68
Mediana: 8
Desv. Estándar: 17.62

Método de Capping



Promedio: 21.56
Mediana: 8
Desv. Estándar: 26.82


Monto gastado en pescado.

Reemplazo de outliers con la mediana:



Promedio: 21.36
Mediana: 12
Desv. Estándar: 27.81


Método de Capping



Promedio: 32.23
Mediana: 12
Desv. Estándar: 40.33


Monto gastado en dulces.

Reemplazo de outliers con la mediana:



Promedio: 14.15
Mediana: 8
Desv. Estándar: 18.54


Método de Capping



Promedio: 22.25
Mediana: 8
Desv. Estándar: 28.04

Monto gastado en productos premium.

Reemplazo de outliers con la mediana:



Promedio: 30.22
Mediana: 25
Desv. Estándar: 28.67


Método de Capping



Promedio: 39.56
Mediana: 25
Desv. Estándar: 39.76

Monto gastado en productos cárnicos.

Reemplazo de outliers con la mediana:




Promedio: 113.31

Mediana: 68

Desv. Estándar: 135.14

Método de Capping



Promedio: 150.86

Mediana: 68

Desv. Estándar: 178.16

04 Reconstrucción de variables categóricas y limpieza final

Marital_Status

Reconstruida a partir de las variables binarias marital_Single, marital_Married, marital_Together, marital_Divorced y marital_Widow, identificando el estado "1" para garantizar una única categoría por cliente. Se eliminó el prefijo "marital_" para poblar el campo final.

Education

Reconstruida a partir de education_Basic, education_Graduation, education_Master, education_PhD y education_2n Cycle, con la misma lógica de identificación del estado "1" y eliminación del prefijo "education_".

Variables eliminadas del dataset

marital_Single, marital_Married, marital_Together, marital_Divorced, marital_Widow, education_Basic, education_Graduation, education_Master, education_PhD, education_2n Cycle, Recency, AcceptedCmp1, AcceptedCmp2, AcceptedCmp3, AcceptedCmp4, Complain, Z_CostContact, Z_Revenue, MntTotal, MntRegularProds.